

Reporte de Análisis y Curación de Datos

Proyecto: Control de Calidad en Muestra de Ventas | Nivel: Técnico-Competitivo

1. Resumen del Proceso

El objetivo de este análisis fue auditar y depurar un conjunto de datos inicial compuesto por **7 registros de ventas**. Durante la fase de diagnóstico estadístico, se observó de manera contundente la presencia de un dato fuera de rango (*outlier*) que distorsionaba el comportamiento financiero real del negocio.

Con el fin de garantizar la integridad del análisis para posteriores tomas de decisiones, se procedió a la fase de curación y limpieza. Mediante este proceso, se eliminó dicho registro anómalo del flujo principal, lo que dio origen a la creación de dos estructuras independientes: un DataFrame limpio y depurado compuesto por **6 registros óptimos**, y un DataFrame secundario que almacena la anomalía aislada para auditoría externa.

2. Evidencia y Validación Estadística

Para fundamentar técnicamente la remoción del registro, el análisis se acompañó de un **Diagrama de Caja (Boxplot)**. Esta herramienta visual permite validar el comportamiento del set de datos bajo los siguientes criterios objetivos:

- **Rango de Normalidad (El 50% de los datos):** La caja central del gráfico delimita visualmente el espacio donde se concentra la mitad de las transacciones más comunes del negocio (comprendidas estrictamente entre los cuartiles **Q1** y **Q3**), reflejando una operación interna sana y compacta.
- **Identificación del Outlier:** El registro correspondiente al monto de **\$9,500.00** se observa de manera clara, explícita y totalmente divorciada del cuerpo principal del gráfico, ubicándose mucho más allá de los límites máximos permitidos por los "bigotes" estadísticos.

3. Resultados de la Segmentación

A continuación se detalla la distribución final de las estructuras resultantes tras la ejecución del pipeline automatizado en Python:

Estructura de Datos	Cantidad de Registros	Estado del Dataset	Propósito en Producción
df_ventas (Inicial)	7	Contaminado	Diagnóstico y cálculo de umbrales.
df_limpios	6	Prolijo / Depurado	Modelado, reportes financieros y analítica avanzada.

Estructura de Datos	Cantidad de Registros	Estado del Dataset	Propósito en Producción
df_anomalias	1	Aislado	Auditoría interna y revisión de seguridad.

Conclusión Técnica: La transición de un set de datos contaminado a un DataFrame prolijo y optimizado reduce el sesgo operativo y evita errores críticos de sobreestimación en las proyecciones de negocio.